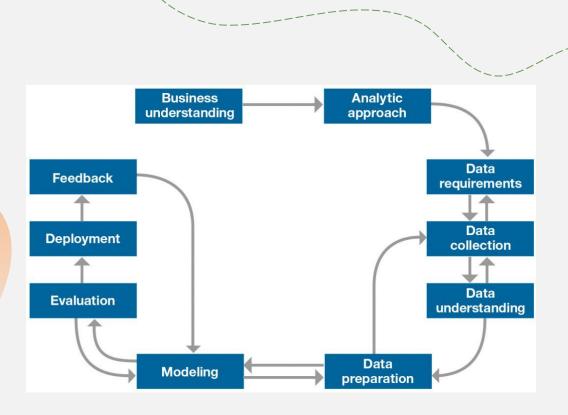


### Metodologi Sains Data





# **Business Understanding**

Melakukan Klarifikasi terhadap masalah

#### **Business Understanding**

#### Goals:

memberikan rekomendasi dengan harapan membantu konsumen mengerucutkan pilihannya

#### Objectives:

Mengembangkan model yang dapat digunakan dalam implementasi sistem rekomendasi agar pengguna mendapatkan rekomendasi yang sesuai.







## Analytic Approach

Menentukan metode analitik

### **Analytic Approach**







# Data Requirements

Menentukan data

### **Data Requirements**

Diperlukan data itemset transaksi-transaksi yang dilakukan oleh setiap pelanggan.

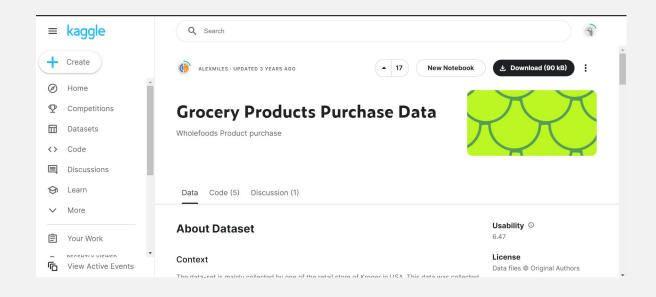




### **Data Collection**

Pengumpulan Data

#### **Data Collections**



#### **Data Collections**





Memahami dan Menganalisis Data

- Ukuran Dataset
   Memiliki 9835 baris dan 32 kolom
- Nama Daftar kolom yang berada dalam dataset

Atribut Data

3. Daftar Tipe data

Semua Kolom memiliki tipe

data object-

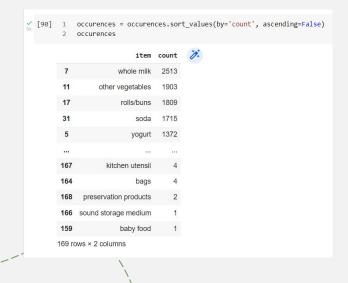
```
Informasi Ukuran Dataset
[14] print('Ukuran data:', df.shape)
     Ukuran data: (9835, 32)
Informasi Atribut Data
 print('Daftar kolom:', df.columns)
     Daftar kolom: Index(['Product 1', 'Product 2', 'Product 3', 'Product 4', 'Product 5'
            'Product 6', 'Product 7', 'Product 8', 'Product 9', 'Product 10',
            'Product 11', 'Product 12', 'Product 13', 'Product 14', 'Product 15',
            'Product 16', 'Product 17', 'Product 18', 'Product 19', 'Product 20',
            'Product 21', 'Product 22', 'Product 23', 'Product 24', 'Product 25',
            'Product 26', 'Product 27', 'Product 28', 'Product 29', 'Product 30',
            'Product 31', 'Product 32'],
           dtype='object')
[16] print('Daftar tipe data:\n' + str(df.dtypes))
     Daftar tipe data:
     Product 1
                   object
     Product 2
                   object
                  object
     Product 3
     Product 4
                  object
```

[] 1	df.head(5)	)																		
	Product 1	Product 2	Product 3	Product 4	Product 5	Product 6	Product 7	Product 8	Product 9	Product 10	Product 23	Product 24	Product 25	Product 26	Product 27	Product 28	Product 29	Product 30	Product 31	Product 32
0	citrus fruit	semi- finished bread	margarine	ready soups	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	tropical fruit	yogurt	coffee	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	whole milk	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	pip fruit	yogurt	cream cheese	meat spreads	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
4	other vegetables		condensed milk	long life bakery product	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN
5 ro	ws × 32 colum	ns																		

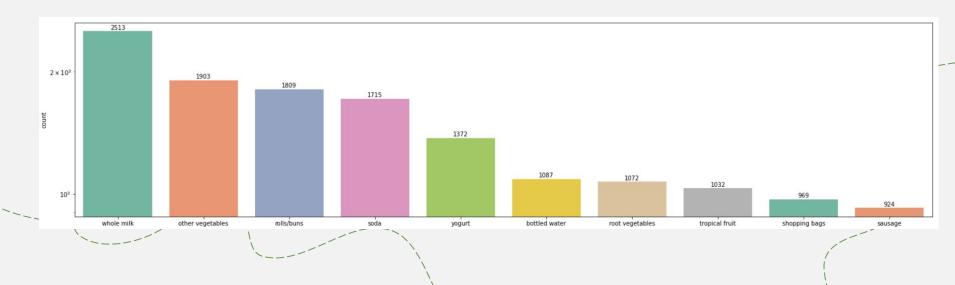
- 4. Exploratory Data Analysis (EDA)
  - Analisis dilakukan hanya dengan melihat distribusi data pada jumlah produk yang dibeli pada setiap transaksi dan disimpan dalam kolom baru dengan nama *count*.

```
df count['Count'].describe()
         9835.000000
count
            4,409456
mean
std
            3.589385
min
            1.000000
25%
            2,000000
50%
            3.000000
75%
            6.000000
           32.000000
max
Name: Count, dtype: float64
```

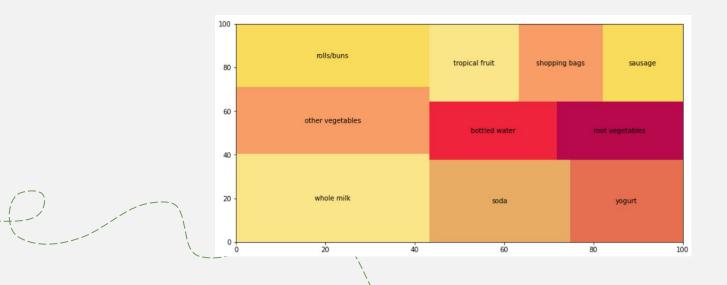
- 4. Exploratory Data Analysis (EDA)
  - Analisis terhadap jumlah pembelian yang telah dilakukan pada setiap item pada data transaksi



- 4. Exploratory Data Analysis (EDA)
  - Visualisasi data dengan bar chart atau bar plot 10 item dengan jumlah pembelian tertinggi dilakukan menggunakan library matplotlib dan seaborn.



- 4. Exploratory Data Analysis (EDA)
  - visualisasi dengan treemap 10 item dengan jumlah pembelian tertinggi, kami menggunakan library squarify.





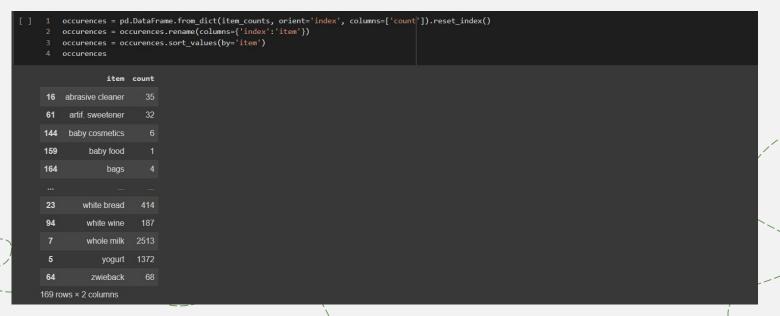
Melakukan Pra-Preproses Data

- 1. Terdapat 271353 sel data yang bernilai None tetapi tidak perlu dilakukan pre proses handling missing value.
- 2. Terdapat 2824 data yang bernilai sama atau terdapat duplikat data.
- 3. Melakukan preprocessing text yaitu case folding

```
for i in df:
    df[i] = df[i].str.lower()
```

4. Melakukan encode pada data transaksi ke dari data frame ke list of lists

5. Melakukan grouping berdasarkan nama item yang sama dan melakukan checking pada masing-masing item



6. Setelah menjadi list of lists, data di-encode dengan kode berikut:

```
te = TransactionEncoder()
te_ary = te.fit(list_cart).transform(list_cart)
te_ary
```

7. Hasil dari data yang telah di encode adalah NumPy array sebagai berikut:

8. Format diubah kembali menjadi dataframe dengan kode sebagai berikut:

```
te_df = pd.DataFrame(te_ary, columns=te.columns_)
te_df.head()
```

9. Preview dataframe:

	abrasive cleaner	artif. sweetener	baby cosmetics	baby food		baking powder	bathroom cleaner	beef	berries	beverages	 uht- milk	vinegar	waffles	whipped/sour cream	whisky	white bread	white wine	whole milk	yogurt	zwieback
0	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False
1	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	True	False
2	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	True	False	False
3	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	True	False
4	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	False	True	False	False
5 rows	× 169 columns																			



### Modelling

Pembuatan Model Machine Learning

### Modelling

Model dibentuk menggunakan algoritma apriori dengan mengimplementasikan library mlxtend.

```
frequent_itemsets = apriori(te_df, min_support=0.015,
use_colnames=True, max_len=4)
for i in frequent_itemsets['itemsets']:
   for j in i:
        j = str.lower(j)
Frequent_itemsets
```

Preview dari rule yang terbentuk adalah sebagai berikut:

	support	itemsets
0	0.017692	(baking powder)
1	0.052466	(beef)
2	0.033249	(berries)
3	0.026029	(beverages)
4	0.080529	(bottled beer)
175	0.023183	(whole milk, root vegetables, other vegetables)
176	0.017082	(whole milk, other vegetables, tropical fruit)
177	0.022267	(yogurt, whole milk, other vegetables)
178	0.015557	(yogurt, whole milk, rolls/buns)
179	0.015150	(yogurt, whole milk, tropical fruit)
80 ro	ws × 2 colu	mns



Pembuatan Model Machine Learning

Melakukan pengujian dengan metrics confidence, dengan menggunakan library mlxtend.

```
association_rules_data = association_rules(frequent_itemsets,
metric="confidence", min_threshold=0.015)
association_rules_data
```

#### Preview dari matrix yang didapat :

	antecedents	consequents	antecedent support	consequent support	support	confidence	lift	leverage	conviction
0	(other vegetables)	(beef)	0.193493	0.052466	0.019725	0.101944	1.943066	0.009574	1.055095
1	(beef)	(other vegetables)	0.052466	0.193493	0.019725	0.375969	1.943066	0.009574	1.292416
2	(root vegetables)	(beef)	0.108998	0.052466	0.017387	0.159515	3.040367	0.011668	1.127366
3	(beef)	(root vegetables)	0.052466	0.108998	0.017387	0.331395	3.040367	0.011668	1.332628
4	(whole milk)	(beef)	0.255516	0.052466	0.021251	0.083168	1.585180	0.007845	1.033487
233	(yogurt, tropical fruit)	(whole milk)	0.029283	0.255516	0.015150	0.517361	2.024770	0.007668	1.542528
234	(whole milk, tropical fruit)	(yogurt)	0.042298	0.139502	0.015150	0.358173	2.567516	0.009249	1.340701
235	(yogurt)	(whole milk, tropical fruit)	0.139502	0.042298	0.015150	0.108601	2.567516	0.009249	1.074380
236	(whole milk)	(yogurt, tropical fruit)	0.255516	0.029283	0.015150	0.059292	2.024770	0.007668	1.031900
237	(tropical fruit)	(yogurt, whole milk)	0.104931	0.056024	0.015150	0.144380	2.577089	0.009271	1.103265

Untuk menggunakan model yang sudah dibuat, digunakan fungsi find() yang didefinisikan sebagai berikut:

```
def find(items, frequent_itemsets):
   out = []
   for i in range(len(frequent_itemsets)):
      if set(items).issubset(frequent_itemsets['itemsets'].iloc[i]):
        out.extend(frequent_itemsets['itemsets'].iloc[i])
   out = list(set([x for x in out if x not in items]))
      return out
```

Contoh penggunaan dan keluarannya adalah sebagai berikut:

```
find(['whole milk', 'root vegetables'], frequent_itemsets)
find(['whole milk', 'root vegetables'], frequent_itemsets)
['other vegetables']
```

```
find(['whole milk'], frequent_itemsets)
```

```
find(['whole milk'], frequent itemsets)
 ['root vegetables',
  'sausage',
  'citrus fruit',
  'frankfurter',
  'beef',
  'rolls/buns',
  'white bread',
  'margarine',
  'newspapers',
  'other vegetables',
  'pip fruit',
  'butter'.
  'pastry',
  'soda',
  'chicken',
  'sugar',
  'whipped/sour cream',
  'yogurt',
  'shopping bags',
  'brown bread',
  'domestic eggs',
  'bottled water',
  'fruit/vegetable juice',
  'chocolate',
  'coffee',
  'bottled beer',
  'napkins',
  'cream cheese',
  'curd',
  'pork',
  'tropical fruit',
  'frozen vegetables']
```



Menempatkan Model Pada Streamlit Cloud

Interface untuk sistem rekomendasi yang dideploy dibangun dengan menggunakan library streamlit. Library lain yang digunakan dalam deployment adalah library pickle untuk melakukan load model. Kode untuk import library adalah sebagai berikut:

```
import streamlit as st
import pickle
```

Sebelum membangun interface, model yang sudah dibuat ketika modelling harus diload terlebih dahulu.

```
file = open('model', 'rb')
data = pickle.load(file)
file.close()
```

Pada interface, di bagian atas dibuat judul program. Kemudian terdapat multiselect untuk memilih item produk dari daftar. Maksimal item yang dapat dipilih adalah dua karena rule set terpanjang pada model berukuran 3.

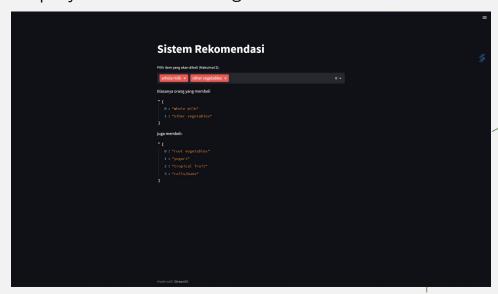
```
st.title('Sistem Rekomendasi')

opt = data[0]
symbols = st.multiselect("Pilih item yang akan dibeli (Maksimal 2
item): ", opt['item'], opt['item'][:2], max selections=2)
```

Masukan pada multiselect akan diproses dengan fungsi find seperti pada tahap evaluation. Kemudian hasilnya akan ditampilkan.

```
def find(items, frequent itemsets):
  out = []
  for i in range(len(frequent itemsets)):
    if set(items).issubset(frequent itemsets['itemsets'].iloc[i]):
      out.extend(frequent itemsets['itemsets'].iloc[i])
  out = list(set([x for x in out if x not in items]))
  return out
st.write('Biasanya orang yang membeli ', symbols, 'juga membeli: ')
st.write(find(symbols, data[1]))
```

Hasil deployment dapat dilihat pada link <a href="https://feminovialina-simple-apriori-recommendation-system-d-app-93n7sm.stream/it.">https://feminovialina-simple-apriori-recommendation-system-d-app-93n7sm.stream/it.</a>
<a href="mailto:app/">app/</a>. Preview hasil deployment adalah sebagai berikut:



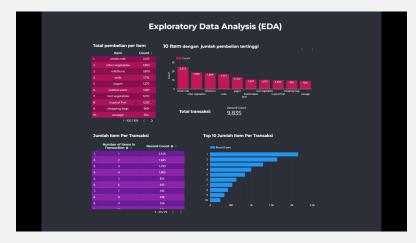


### Feedback

Mendapatkan Umpan Balik tentang Kinerja Model

#### Feedback

Dashboard sebagai salah satu hasil akan memberikan visualisasi dan laporan dari hal-hal yang telah dilakukan pada tahap sebelumnya. Dashboard dibuat menggunakan Google Data Studio dan dapat diakses melalui <a href="https://datastudio.google.com/reporting/5bcdc6f8-d0a5-42ae-b76d-91433869be18">https://datastudio.google.com/reporting/5bcdc6f8-d0a5-42ae-b76d-91433869be18</a>.



### Thanks!

Do you have any questions?

